UNIVERSITÉ DE HAUTE-ALSACE

Faculté des Sciences et Techniques

MÉMOIRE

Test non paramétrique de Wilcoxon

Cyprien LORIC

Encadré par

Nicolas JUILLET

Année universitaire 2025–2026

Table des matières

Introduction **3**

1 Fondements probabilistes **5**
1.1 Espace probabilisé 5
1.2 Variables aléatoires réelles 5
1.3 Distributions continues et symétriques 6
1.4 Indépendance mutuelle 8
1.4.1 Densité d'une différence de variables indépendantes 8
1.5 Espérance et variance 9
1.6 Loi de Bernoulli 11

2 Outils asymptotiques **12**
2.1 Convergence en loi 12
2.2 Loi normale et stabilité 12
2.3 Opérateur de convolution 13
2.4 Développements de Taylor 15

3 Le théorème central limite de Lindeberg **17**
3.1 Cadre et notations 17
3.2 La condition de Lindeberg 17
3.3 Énoncé et démonstration 18

4 Théorie générale des tests statistiques **20**
4.1 Hypothèses nulle et alternative 20

5 Approche exacte du test de Wilcoxon **22**
5.1 Le cas apparié (Signed Rank Test) 23
5.2 Le cas non-apparié (Rank Sum Test) 25
5.5 Implémentation algorithmique 25
5.5.1 Approche combinatoire exacte 25
5.5.2 Approche asymptotique via Lindeberg 31

6 Approche asymptotique **32**
6.1 Statistique sous H_0 . . . 32
6.2 Décomposition et vérification de la condition de Lindeberg . . . 35
6.3 Convergence en loi et niveau asymptotique . . . 36

7 Application sur données Réelles **37**
7.1 Présentation des données . . . 37
7.2 Statistiques descriptives . . . 38
7.3 Justification du choix du test : . . . 38
7.4 Application du test . . . 39
7.5 Analyse de la sensibilité . . . 40
7.6 Application du test de Wilcoxon signé-rangé : la réforme Blanquer a-t-elle amélioré la valeur ajoutée ? . . . 41
7.7 Analyse de la puissance des tests . . . 42
7.8 Limites et biais possibles : . . . 43
7.9 Conclusion . . . 44

A Code Python **46**
A.1 Bibliothèques et chargement des données . . . 46
A.2 Statistiques descriptives (2025) . . . 46
A.3 Justification du choix du test . . . 47
A.4 Question 1 : Mann-Whitney (Wilcoxon rang-somme) . . . 48
A.5 Question 2 : Wilcoxon signé-rangé . . . 50
A.6 Analyse de la puissance des tests . . . 52

Bibliographie **54**

Introduction

Aujourd'hui, la demande de preuve scientifique et rigoureuse est omniprésente. Une réforme scolaire a-t-elle réellement été efficace, ou observons-nous simplement une variabilité naturelle d'une année à l'autre ? Un médicament est-il efficace, ou s'agit-il simplement d'une chance statistique de guérison ? L'aide à la décision passe de plus en plus souvent par des outils statistiques, permettant de juger de l'efficacité réelle d'un produit, d'une politique publique, d'une réforme. De manière assez classique pour ce genre de questions, on utilise le test de Student. Cependant, ce dernier suppose que les données suivent une loi normale — hypothèse qui, dans la réalité, est rarement parfaitement vérifiée dans des pratiques sociétales, économiques ou biologiques. Une alternative a été développée pour s'affranchir de cette contrainte. C'est l'objet de l'article de Frank Wilcoxon publié en 1945 dans Biometrics Bulletin : "Individual Comparisons by Ranking Methods". Wilcoxon propose de substituer les valeurs observées par leurs rangs dans un échantillon trié. Cela permet de ne plus dépendre d'une hypothèse sur la distribution des données. Il s'agit donc d'un test non paramétrique. Il distingue deux cas distincts : un cas dit apparié et un second dit non apparié. Dans le premier, on mesure les mêmes observations avant et après un traitement. Dans le second, on observe deux échantillons indépendants et l'on cherche à savoir s'ils proviennent de la même distribution. L'objectif de ce mémoire est de présenter ces tests de façon rigoureuse et de justifier leur comportement lorsque le nombre d'observations devient grand. Ces outils seront ensuite appliqués à une situation réelle. Dans un contexte où de nombreux lycées fusionnent pour des raisons économiques et où le débat public questionne régulièrement la qualité de l'éducation en France, on cherchera à savoir si la taille d'un lycée influence sa valeur ajoutée au taux de réussite. De nombreuses réformes ont eu lieu ces dernières années, dans un climat d'instabilité politique qui alimente ce débat : les réformes Chatel et Blanquer ont-elles modifié les performances des lycées ? Nous tenterons de répondre à ces questions grâce à des données publiques disponibles sur data.gouv.fr. Cette application permettra également d'illustrer comment un outil statistique conçu pour la biologie peut finalement avoir une portée universelle.

Le mémoire s'organise en sept chapitres. Les chapitres 1 et 2 posent les fondements probabilistes et les outils asymptotiques nécessaires à la suite. Le chapitre 3 établit le

théorème central limite dans sa version généralisée due à Lindeberg, pierre angulaire de la justification asymptotique. Le chapitre 4 rappelle le cadre général des tests statistiques. Les chapitres 5 et 6 développent respectivement l'approche exacte et l'approche asymptotique du test de Wilcoxon. Enfin, le chapitre 7 applique ces outils à des données réelles issues des indicateurs de valeur ajoutée des lycées français.

Chapitre 1

Fondements probabilistes

1.1 Espace probabilisé

Définition 1.1 (Tribu, σ-algèbre)**.** Un sous-ensemble $\mathcal{F}$ de $\mathcal{P}(\Omega)$ est appelé tribu (ou σ-algèbre) si les propriétés suivantes sont satisfaites :

(i) $\Omega \in \mathcal{F}$;

(ii) pour tout $A \in \mathcal{F}$, $A^c \in \mathcal{F}$;

(iii) pour toute suite $(A_n)_{n\in\mathbb{N}}$ d'éléments de $\mathcal{F}$, $\bigcup_n A_n \in \mathcal{F}$.

Définition 1.2 (Tribu des boréliens)**.** Soit $\Omega = \mathbb{R}$ et $\mathcal{C}$ l'ensemble des intervalles $]-\infty, a]$ pour $a \in \mathbb{R}$. La tribu $\sigma(\mathcal{C})$ s'appelle la tribu des boréliens de $\mathbb{R}$, notée $\mathcal{B}(\mathbb{R})$, et contient tous les intervalles de $\mathbb{R}$.

Définition 1.3 (Mesure de probabilité, espace probabilisé)**.** Une mesure de probabilité sur $(\Omega, \mathcal{F})$ est une application $P : \mathcal{F} \to [0, 1]$ possédant les deux propriétés suivantes :

(i) $P(\Omega) = 1$

(ii) (σ-additivité) pour toute suite (finie ou dénombrable infinie) (A_n) d'éléments deux-à-deux disjoints de $\mathcal{F}$, on a

$$P\left(\bigcup_n A_n\right) = \sum_n P(A_n).$$

Le triplet $(\Omega, \mathcal{F}, P)$ est un espace probabilisé ou un espace de probabilité.

1.2 Variables aléatoires réelles

Définition 1.4 (Variable aléatoire)**.** Une application $X : \Omega \to \mathbb{R}$ est appelée variable aléatoire réelle si, pour tout intervalle $I \subset \mathbb{R}$, l'ensemble $\{X \in I\} := X^{-1}(I) = \{\omega \in \Omega :$

$X(\omega) \in I\}$ appartient à la tribu $\mathcal{F}$.

Définition 1.5 (Loi d'une variable aléatoire)**.** L'application $P_X : \mathcal{B}(\mathbb{R}) \to [0,1]$, définie par

$$P_X(A) = P(X^{-1}(A))$$

pour tout $A \in \mathcal{B}(\mathbb{R})$, s'appelle la loi de probabilité de la v.a.r X.

Définition 1.6 (Fonction de répartition)**.** Soit $(\Omega, \mathcal{F}, P)$ un espace probabilisé et $X : \Omega \to \mathbb{R}$ une v.a.r. On appelle *fonction de répartition* de X la fonction

$F_X(x) = P(X \leq x) = P(X^{-1}(]-\infty, x])$ pour tout $x \in \mathbb{R}$.

1.3 Distributions continues et symétriques

Définition 1.7 (Variable aléatoire à densité)**.** On dit que X est une v.a.r à densité ou v.a.r continue si sa fonction de répartition F_X s'écrit

$F_X(x) = \int_{-\infty}^{x} f(t)\,dt$ pour tout $x \in \mathbb{R}$

pour une fonction $f : \mathbb{R} \to \mathbb{R}$, appelée densité de X, avec les propriétés suivantes :

1. $f \geq 0$;
2. f est continue sur $\mathbb{R}$, sauf éventuellement en un nombre fini de points ;
3. $\int_{-\infty}^{+\infty} f(t)\,dt = 1$.

Proposition 1.1. *Soit Z une variable aléatoire admettant une densité f_Z. Alors Z et $-Z$ ont la même loi si et seulement si f_Z est paire.*

Démonstration. Calculons la fonction de répartition de $-Z$ pour tout $x \in \mathbb{R}$:

$$F_{-Z}(x) = P(-Z \leq x) = P(Z \geq -x) = 1 - P(Z < -x) = \int_{-\infty}^{+\infty} f_Z(t)dt - \int_{-\infty}^{-x} f_Z(t)dt = \int_{-x}^{+\infty} f_Z(t)\,dt$$

On réalise un changement de variable, on pose $s = -t$, on a donc $t = -s$ et $dt = -ds$.

$$F_{-Z}(x) = \int_{x}^{-\infty} f_Z(-s)(-ds) = \int_{-\infty}^{x} f_Z(-s)\,ds$$

Par identification on a donc

$$F_{-Z}(x) = F_Z(-x)$$

($\Rightarrow$) Supposons f_Z paire.

$$f_{-Z}(x) = f_Z(-x) = f_Z(x)$$

Donc $-Z$ et Z ont la même loi.

($\Leftarrow$)

Supposons que Z et $-Z$ ont la même loi. C'est-à-dire $f_{-Z}(x) = f_Z(x)$ pour tout x. Or on a montré que $f_{-Z}(x) = f_Z(-x)$. Donc :

$$f_Z(-x) = f_Z(x) \quad \text{pour tout } x$$

Donc f_Z est paire. ■

Corollaire 1.1. *Soit Z une variable aléatoire admettant une densité paire f_Z. Alors :*

1. $P(Z = 0) = 0$;
2. $P(Z > 0) = P(Z < 0) = \dfrac{1}{2}$;
3. *si l'espérance de Z existe, alors $E[Z] = 0$.*

Démonstration. **(a)** Comme Z est une variable aléatoire à densité, tout singleton est de probabilité nulle (Définition 1.7) :

$$P(Z = 0) = \int_0^0 f_Z(t)\, dt = 0.$$

(b) On a :

$$P(Z > 0) + P(Z = 0) + P(Z < 0) = 1.$$

Par (a), $P(Z = 0) = 0$, donc $P(Z > 0) + P(Z < 0) = 1$. On calcule :

$$P(Z > 0) = \int_0^{+\infty} f_Z(t)\, dt.$$

On effectue le changement de variable $s = -t$, donc $t = -s$ et $dt = -ds$.Donc :

$$P(Z > 0) = \int_0^{-\infty} f_Z(-s)(-ds) = \int_{-\infty}^0 f_Z(-s)\, ds.$$

Comme f_Z est paire, $f_Z(-s) = f_Z(s)$, donc :

$$P(Z > 0) = \int_{-\infty}^0 f_Z(s)\, ds = P(Z < 0).$$

Comme leur somme vaut 1, on conclut :

$$P(Z > 0) = P(Z < 0) = \frac{1}{2}.$$

(c) Par définition de l'espérance (Définition 1.9) :

$$E[Z] = \int_{-\infty}^{+\infty} x\, f_Z(x)\, dx.$$

La fonction $x \mapsto x \cdot f_Z(x)$ est impaire : c'est le produit de la fonction impaire $x \mapsto x$ et de la fonction paire f_Z. L'intégrale d'une fonction impaire sur un domaine symétrique est nulle, donc $E[Z] = 0$. ■

1.4 Indépendance mutuelle

Définition 1.8 (Indépendance d'une famille d'évènements)**.** Soit $(\Omega, \mathcal{F}, P)$ un espace de probabilité et soit $(A_i)_{i\in I}$ une famille (finie ou infinie) d'évènements dans $\mathcal{F}$.

- On dit que les évènements A_i sont mutuellement indépendants si, pour toute partie finie $J \subset I$, on a

$$P(\cap_{j\in J} A_j) = \prod_{j\in J} P(A_j).$$

1.4.1 Densité d'une différence de variables indépendantes

Proposition 1.2. *Soient X et Y deux variables aléatoires indépendantes admettant chacune une densité f_X et f_Y.*

Partie A : *$Z = X - Y$ admet une densité donnée par :*

$$f_Z(z) = \int_{-\infty}^{+\infty} f_X(x) f_Y(x - z)\, dx$$

Partie B : *Si de plus $f_X = f_Y = f$, alors f_Z est paire, donc Z est symétrique autour de 0.*

Démonstration. **Démonstration Partie A.**

Pour tout $z \in \mathbb{R}$:

$$F_Z(z) = P(Z \leq z) = P(X - Y \leq z) = P(X \leq Y + z) = \iint_{\{x\leq y+z\}} f_X(x) f_Y(y)\, dx\, dy$$

$$= \int_{-\infty}^{+\infty} \int_{-\infty}^{y+z} f_X(x)\,dx\, f_Y(y)\,dy = \int_{-\infty}^{+\infty} F_X(y+z) f_Y(y)\,dy$$

On dérive par rapport à z. On admet qu'on peut dériver sous le signe intégrale :

$$f_Z(z) = \frac{d}{dz} F_Z(z) = \int_{-\infty}^{+\infty} f_X(y+z)\, f_Y(y)\,dy$$

On pose $x = y + z$, donc $y = x - z$ et $dy = dx$:

$$f_Z(z) = \int_{-\infty}^{+\infty} f_X(x)\, f_Y(x-z)\,dx$$

On vérifie que f_Z est bien une densité au sens de la Définition 1.7 :

1. $f_Z(z) \geq 0$ car $f_X \geq 0$ et $f_Y \geq 0$.
2. On pose $u = x - z$, donc $dz = du$:

$$\int_{-\infty}^{+\infty} f_Z(z)\,dz = \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} f_X(x) f_Y(x-z)\,dx\,dz = \int_{-\infty}^{+\infty} f_X(x) \left(\int_{-\infty}^{+\infty} f_Y(u)\,du \right) dx = 1$$

Donc Z admet f_Z comme densité.

Démonstration Partie B.

On suppose $f_X = f_Y = f$. On calcule $f_Z(-z)$:

$$f_Z(-z) = \int_{-\infty}^{+\infty} f(x)\, f(x+z)\,dx$$

On pose $u = x + z$, donc $x = u - z$ et $dx = du$:

$$f_Z(-z) = \int_{-\infty}^{+\infty} f(u-z)\, f(u)\,du = \int_{-\infty}^{+\infty} f(u)\, f(u-z)\,du = f_Z(z)$$

Donc f_Z est paire. Par la Proposition 1.1, Z est symétrique autour de 0.

■

1.5 Espérance et variance

Définition 1.9 (Espérance)**.** On dit que X admet une espérance si l'intégrale de $\int_{-\infty}^{+\infty} |x| f(x)dx$ existe ; dans ce cas, on définit son espérance, notée $E[X]$, par

$$\mathbb{E}[X] = \int_{-\infty}^{+\infty} x f(x) dx.$$

Proposition 1.3 (Linéarité de l'espérance)**.** *Soient $X, Y : \Omega \to \mathbb{R}$ des v.a.r intégrables, et $a \in \mathbb{R}$. On a alors : $\mathbb{E}[aX + Y] = aE[X] + E[Y]$*

Démonstration. Par définition de l'intégrale par rapport à P,

$$\mathbb{E}[aX + Y] = \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} (ax + y) f_{X,Y}(x, y) dx dy.$$

par linéarité de l'intégrale

$$\mathbb{E}[aX + Y] = a \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} x f_{X,Y}(x, y) dx dy + \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} y f_{X,Y}(x, y) dx dy.$$

$$\mathbb{E}[aX + Y] = a \int_{-\infty}^{+\infty} x (\int_{-\infty}^{+\infty} f_{X,Y}(x, y) dy) dx + \int_{-\infty}^{+\infty} y (\int_{-\infty}^{+\infty} f_{X,Y}(x, y) dx) dy.$$

$$\mathbb{E}[aX + Y] = a \int_{-\infty}^{+\infty} x f_X(x) dx + \int_{-\infty}^{+\infty} y f_Y(y) dy.$$

$$\mathbb{E}[aX + Y] = a\mathbb{E}[X] + \mathbb{E}[Y].$$

■

Proposition 1.4 (Formule de transfert)**.** *Soit $Z = (X, Y)$ un vecteur aléatoire à densité f. Soit $g : \mathbb{R}^2 \to \mathbb{R}$ une fonction continue (ou plus généralement mesurable). On suppose que l'intégrale*

$$\int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} |g(x, y)| \, f(x, y) \, dx \, dy$$

est finie. Alors la variable aléatoire réelle $g(X, Y)$ possède une espérance et on a :

$$\mathbb{E}\big[g(X, Y)\big] = \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} g(x, y) \, f(x, y) \, dx \, dy.$$

Définition 1.10 (Variance)**.** Supposons que X admet une espérance. On appelle la variance de X,

$Var(X) = \int_{-\infty}^{+\infty} (x - E[X])^2 f(x) dx = \mathbb{E}[X^2] - \mathbb{E}[X]^2$

Proposition 1.5 (Variance d'une somme de variables indépendantes)**.** *Si $X_1, ..., X_n$ sont mutuellement indépendantes et de carré intégrable,*

$$\mathrm{Var}(X_1 + \cdots + X_n) = \mathrm{Var}(X_1) + \cdots + \mathrm{Var}(X_n).$$

Démonstration.

$$\begin{aligned}
\mathrm{Var}(\sum_i^n X_i) &= \mathbb{E}[(\sum_i^n X_i)^2] - \mathbb{E}[\sum_i^n X_i]^2 \\
&= \mathbb{E}[\sum_i^n X_i^2 + \sum_{i\neq j}^n X_i X_j] - \sum_i^n \mathbb{E}[X_i]^2 - \sum_{i\neq j}^n \mathbb{E}[X_i]\mathbb{E}[X_j] \\
&= \sum \mathbb{E}[X_i^2] + \sum_{i\neq j}^n \mathbb{E}[X_i]\mathbb{E}[X_j] - \sum \mathbb{E}[X_i]^2 - \sum \mathbb{E}[X_i]\mathbb{E}[X_j] \\
&= \sum_i^n \mathrm{Var}(X_i)
\end{aligned}$$

■

1.6 Loi de Bernoulli

Définition 1.11 (Loi de Bernoulli)**.** Une variable aléatoire X suit une loi de Bernoulli de paramètre $p \in [0,1]$, notée $X \sim \mathcal{B}(p)$, si sa fonction de répartition est

$$F_X(t) = (1-p)\mathbf{1}_{t\in[0,1[} + \mathbf{1}_{t\geq 1}.$$

En particulier, $\mathbb{P}(X=1) = p$, $\mathbb{P}(X=0) = 1-p, \mathbb{E}[X] = p$ et $\mathrm{Var}(X) = p(1-p)$.

Chapitre 2

Outils asymptotiques

2.1 Convergence en loi

Définition 2.1 (Convergence en loi)**.** Soit $(X_n)_{n\geq 1}$ une suite de v.a.r. On dit que la suite converge en loi vers X si et seulement si

$$\forall f \in C_b(\mathbb{R}), \mathbb{E}(f(X_n)) \xrightarrow[n\to+\infty]{\mathcal{L}} \mathbb{E}(f(X)).$$

où $\mathcal{C}_b(\mathbb{R})$ est l'espace des fonctions continues bornées sur $\mathbb{R}$

Propriété 2.1. *Pour montrer $X_n \xrightarrow{\mathcal{L}} X$, il suffit de vérifier que $\mathbb{E}[f(X_n)] \to \mathbb{E}[f(X)]$ pour toute $f \in C_b^2(\mathbb{R})$.*

Démonstration. cf LindebergRapport 1.2 p5 ■

2.2 Loi normale et stabilité

Définition 2.2 (Loi normale)**.** On dit que X suit une loi normale de paramètres $\mu \in \mathbb{R}, \sigma > 0$, si X admet comme densité la fonction $f_{\mu,\sigma}$, définie par :

$f_{\mu,\sigma}(x) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$ pour tout $x \in \mathbb{R}$. On écrira alors $X \sim \mathcal{N}(\mu, \sigma^2)$

Proposition 2.1 (Stabilité de la loi normale)**.** *Soient $X \sim \mathcal{N}(\mu_1, \sigma_1^2)$ et $Y \sim \mathcal{N}(\mu_2, \sigma_2^2)$ deux variables indépendantes. Alors*

$$X + Y \sim \mathcal{N}(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2).$$

Proposition 2.2. *(Fonction caractéristique de la loi normale)*

Si X suit une loi normale $\mathcal{N}(\mu, \sigma^2)$, alors sa fonction caractéristique est donnée, pour tout $t \in \mathbb{R}$, par :

$$\varphi_X(t) = \exp\left(i\mu t - \frac{\sigma^2 t^2}{2}\right)$$

Démonstration. La fonction caractéristique d'une variable $Z \sim \mathcal{N}(\mu, \sigma^2)$ est $\varphi_Z(t) = \exp(i\mu t - \sigma^2 t^2/2)$ pour tout $t \in \mathbb{R}$. Comme X et Y sont indépendants, on a, pour tout $t \in \mathbb{R}$,

$$\varphi_{X+Y}(t) = \mathbb{E}[e^{it(X+Y)}] = \mathbb{E}[e^{itX}]\,\mathbb{E}[e^{itY}] = \varphi_X(t)\,\varphi_Y(t),$$

soit

$$\varphi_{X+Y}(t) = \exp\left(i\mu_1 t - \frac{\sigma_1^2 t^2}{2}\right)\exp\left(i\mu_2 t - \frac{\sigma_2^2 t^2}{2}\right) = \exp\left(i(\mu_1+\mu_2)t - \frac{(\sigma_1^2+\sigma_2^2)t^2}{2}\right).$$

La fonction caractéristique caractérisant la loi, on a alors $X+Y \sim \mathcal{N}(\mu_1+\mu_2, \sigma_1^2+\sigma_2^2)$. ■

2.3 Opérateur de convolution

Définition 2.3 (Opérateur de convolution)**.** Soit Z une v.a.r. Posons

$$\begin{aligned} T_Z : \mathcal{C} &\to \mathcal{C} \\ f &\mapsto (x \mapsto E(f(Z+x))) \end{aligned}$$

Propriété 2.2 (Composition)**.** *Soient X et Y deux variables aléatoires indépendantes. Alors*

$$T_{X+Y} = T_X \circ T_Y.$$

Démonstration.

$$\begin{aligned} T_{X+Y}(f)(x) &= \mathbb{E}[f(X+Y+x)] \\ &= \int_{-\infty}^{+\infty}\int_{-\infty}^{+\infty} \varphi(x+u+v) f_{X+Y}(u,v)\,du\,dv \\ &= \int_{-\infty}^{+\infty}\int_{-\infty}^{+\infty} \varphi(x+u+v) f_X(u) f_Y(v)\,du\,dv \\ &= \int_{-\infty}^{+\infty} f_X(u)\Big(\int_{-\infty}^{+\infty} \varphi(x+u+v) f_Y(v)\,dv\Big)\,du \end{aligned}$$

d'après la définition, on a en posant $y = x + u$

$$\int_{-\infty}^{+\infty} \varphi(x+u+v) f_Y(v) dv = \int_{-\infty}^{+\infty} \varphi(y+v) f_Y(v) dv \tag{2.1}$$
$$= T_Y(\varphi)(y) \tag{2.2}$$
$$= T_Y(\varphi)(x+u) \tag{2.3}$$

Donc on a

$$= \int_{\mathbb{R}} T_Y(f)(x+u) f_X(u) du \tag{2.4}$$
$$= \mathbb{E}[T_Y(f)(x+X)] \tag{2.5}$$
$$= T_X(T_Y(f))(x) \tag{2.6}$$

■

Propriété 2.3 (Télescopage)**.** *Soient $X_1, \ldots, X_n$ et $Y_1, \ldots, Y_n$ des variables aléatoires et $T_{X_1}, \ldots, T_{X_n}, T_{Y_1}, \ldots, T_{Y_n}$ les opérateurs de convolution associés. Alors, pour toute fonction bornée f,*

$$\|T_{X_1} \circ \cdots \circ T_{X_n}(f) - T_{Y_1} \circ \cdots \circ T_{Y_n}(f)\|_\infty \leq \sum_{k=1}^{n} \|T_{X_k}(f) - T_{Y_k}(f)\|_\infty.$$

Démonstration. **Étape 1 : termes intermédiaires.** On définit pour $k = 0, 1, ..., n$ les chaînes partiellement swappées :

$$S_k = T_{Y_1} \circ \cdots \circ T_{Y_k} \circ T_{X_{k+1}} \circ \cdots \circ T_{X_n}(f)$$

Ainsi $S_0 = T_{X_1} \circ \cdots \circ T_{X_n}(f)$ est la chaîne X entière et $S_n = T_{Y_1} \circ \cdots \circ T_{Y_n}(f)$ est la chaîne Y entière. On passe de l'une à l'autre en n petits pas, en remplaçant T_{X_k} par T_{Y_k} un à la fois.

Étape 2 : décomposition télescopique. On écrit l'écart total comme une somme télescopique :

$$S_0 - S_n = \sum_{k=0}^{n-1} (S_k - S_{k+1})$$

les termes intermédiaires s'annulant deux à deux. Par l'inégalité triangulaire :

$$\|S_0 - S_n\|_\infty \leq \sum_{k=0}^{n-1} \|S_k - S_{k+1}\|_\infty$$

Étape 3 : majoration de chaque écart élémentaire. Deux termes consécutifs S_k et S_{k+1} ne diffèrent que par un seul swap : $T_{X_{k+1}}$ remplacé par $T_{Y_{k+1}}$. On pose $\varphi = T_{X_{k+2}} \circ \cdots \circ T_{X_n}(f)$ la partie commune à droite, de sorte que :

$$S_k - S_{k+1} = T_{Y_1} \circ \cdots \circ T_{Y_k}\Big(T_{X_{k+1}}(\varphi) - T_{Y_{k+1}}(\varphi)\Big)$$

Par la propriété de contraction $\|T_Z(g)\|_\infty \leq \|g\|_\infty$, appliquée k fois à $T_{Y_1} \circ \cdots \circ T_{Y_k}$, puis au fait que φ est elle-même une contraction de f :

$$\|S_k - S_{k+1}\|_\infty \leq \|T_{X_{k+1}}(\varphi) - T_{Y_{k+1}}(\varphi)\|_\infty \leq \|T_{X_{k+1}}(f) - T_{Y_{k+1}}(f)\|_\infty$$

Étape 4 : conclusion. En sommant sur $k = 0, ..., n-1$:

$$\|T_{X_1} \circ \cdots \circ T_{X_n}(f) - T_{Y_1} \circ \cdots \circ T_{Y_n}(f)\|_\infty \leq \sum_{k=1}^{n} \|T_{X_k}(f) - T_{Y_k}(f)\|_\infty$$

■

2.4 Développements de Taylor

Théorème 2.1 (Formule de Taylor avec reste intégral)**.** *Soit $f : \mathbb{R} \to \mathbb{R}$ avec $f \in \mathcal{C}^{n+1}$. Pour tous $x, h \in \mathbb{R}$,*

$$f(x+h) = f(x) + \frac{h}{1!}f'(x) + \cdots + \frac{h^n}{n!}f^{(n)}(x) + \int_0^h \frac{(h-t)^n}{n!} f^{(n+1)}(x+t)\, dt.$$

Démonstration. **Initialisation.** D'après la formule fondamentale du calcul intégral,

$$\int_0^h f'(x+t)\, dt = f(x+h) - f(x)$$

c'est-à-dire

$$f(x+h) = f(x) + \int_0^h f'(x+t)\, dt.$$

Donc $\mathcal{P}(0)$ est vraie.

Hérédité. Soit $n \in \mathbb{N}$ tel que $\mathcal{P}(n)$ est vraie. Soit f de classe $\mathcal{C}^{n+2}$. Alors f est de classe $\mathcal{C}^{n+1}$ et donc

$$f(x+h) = f(x) + \frac{h}{1!}f'(x) + \cdots + \frac{h^n}{n!}f^{(n)}(x) + \int_0^h \frac{(h-t)^n}{n!} f^{(n+1)}(x+t)\, dt.$$

On pose

$$u(t) = f^{(n+1)}(x+t) \qquad u'(t) = f^{(n+2)}(x+t)$$

$$v'(t) = \frac{(h-t)^n}{n!} \qquad v(t) = -\frac{(h-t)^{n+1}}{(n+1)!}.$$

On a donc

$$\int_0^h \frac{(h-t)^n}{n!} f^{(n+1)}(x+t)\,dt = \left[\frac{-(h-t)^{n+1}}{(n+1)!} f^{(n+1)}(x+t)\right]_0^h + \int_0^h \frac{(h-t)^{n+1}}{(n+1)!} f^{(n+2)}(x+t)\,dt \tag{2.7}$$

$$= \frac{h^{n+1}}{(n+1)!} f^{(n+1)}(x) + \int_0^h \frac{(h-t)^{n+1}}{(n+1)!} f^{(n+2)}(x+t)\,dt. \tag{2.8}$$

Donc on a $\mathcal{P}(n+1)$ vraie. ■

Chapitre 3

Le théorème central limite de Lindeberg

3.1 Cadre et notations

Hypothèse 3.1. Soit $(X_i)_{i\geq 1}$ une suite de variables aléatoires réelles définies sur $(\Omega, \mathcal{A}, P)$ telle que :

1. les X_i sont mutuellement indépendantes ;
2. $\mathbb{E}[X_i] = 0$ pour tout i (variables centrées) ;
3. $\sigma_i^2 = \mathrm{Var}(X_i) < +\infty$ pour tout i.

On pose

$$S_n = \sum_{i=1}^{n} X_i \quad \text{et} \quad s_n^2 = \sum_{i=1}^{n} \sigma_i^2 = \mathrm{Var}(S_n).$$

3.2 La condition de Lindeberg

Définition 3.1 (Condition de Lindeberg)**.** La suite (X_n) vérifie le *critère de Lindeberg* si et seulement si : pour tout $\delta > 0$,

$$\lim_{n\to+\infty} \frac{1}{s_n^2} \sum_{i=1}^{n} \int_{|x|\leq \delta s_n} x^2 P_{X_i}(dx) = 0.$$

3.3 Énoncé et démonstration

Théorème 3.1 (Lindeberg)**.** *Soit (X_i) une suite vérifiant l'Hypothèse 3.1 et la condition de Lindeberg (Définition 3.1). Alors*

$$\frac{S_n}{s_n} \xrightarrow{\mathcal{L}} \mathcal{N}(0,1) \quad \textit{lorsque } n \to +\infty.$$

Démonstration. On pose $\sigma = \dfrac{1}{s_n}$, de sorte que $\dfrac{S_n}{s_n} = \sum_{i=1}^n \sigma X_i$. On introduit $Y \sim \mathcal{N}(0,1)$ ainsi que, pour chaque i, la variable gaussienne $\sigma_i Y$ vérifiant $\mathrm{Var}(\sigma \cdot \sigma_i Y) = \sigma^2\sigma_i^2 = \mathrm{Var}(\sigma X_i)$.

Étape 1 : application du lemme de télescopage. Soit $f \in C_b^2(\mathbb{R})$. On écrit :

$$\begin{aligned}\left|\mathbb{E}\left[f\left(\frac{S_n}{s_n}\right)\right] - \mathbb{E}[f(Y)]\right| &= |T_{\sigma X_1} \circ \cdots \circ T_{\sigma X_n}(f)(0) - T_{\sigma\sigma_1 Y} \circ \cdots \circ T_{\sigma\sigma_n Y}(f)(0)| \\ &\leq \|T_{\sigma X_1} \circ \cdots \circ T_{\sigma X_n}(f) - T_{\sigma\sigma_1 Y} \circ \cdots \circ T_{\sigma\sigma_n Y}(f)\|_\infty \\ &\leq \sum_{i=1}^n \|T_{\sigma X_i}(f) - T_{\sigma\sigma_i Y}(f)\|_\infty ,\end{aligned}$$

la dernière inégalité venant de la Propriété 2.3.

Étape 2 : développement de Taylor. On applique la formule de Taylor (Théorème 2.1) à chaque terme. Pour tout $x \in \mathbb{R}$, en posant $Z = \sigma X_i$:

$$T_Z(f)(x) = f(x) + \mathbb{E}[Z]f'(x) + \frac{\mathbb{E}[Z^2]}{2}f''(x) + R_i(x),$$

où $R_i(x) = \mathbb{E}\Big[\int_0^Z (Z-t)\,[f''(x+t) - f''(x)]\,dt\Big]$ est le reste. Le même calcul pour $Z = \sigma\sigma_i Y$ donne le même terme principal $\dfrac{\sigma^2\sigma_i^2}{2}f''(x)$, car :

$$\mathbb{E}[\sigma X_i] = 0 = \mathbb{E}[\sigma\sigma_i Y] \qquad \text{et} \qquad \mathbb{E}[(\sigma X_i)^2] = \sigma^2\sigma_i^2 = \mathbb{E}[(\sigma\sigma_i Y)^2].$$

Les termes principaux se compensent donc exactement, et :

$$\|T_{\sigma X_i}(f) - T_{\sigma\sigma_i Y}(f)\|_\infty \leq \|R_i\|_\infty + \|R_i'\|_\infty,$$

où R_i et R_i' sont les restes associés à σX_i et $\sigma\sigma_i Y$.

Étape 3 : majoration du reste. Soit $\varepsilon > 0$. Par uniforme continuité de f'', il existe $\delta > 0$ tel que $|t| \leq \delta \Rightarrow |f''(x+t) - f''(x)| \leq \varepsilon$. On sépare selon $\{|\sigma X_i| \leq \delta\}$ et son

complémentaire :

$$\|R_i\|_\infty \leq \frac{\sigma^2\sigma_i^2}{2}\,\varepsilon + \|f''\|_\infty \cdot \mathbb{E}\Big[(\sigma X_i)^2 \cdot \mathbf{1}_{|\sigma X_i|>\delta}\Big]\,.$$

Le même type de majoration s'applique à R_i'.

Étape 4 : conclusion. En sommant sur $i = 1, ..., n$:

$$\sum_{i=1}^{n}(\|R_i\|_\infty + \|R_i'\|_\infty) \leq \varepsilon(1 + 2\|f''\|_\infty) + 4\|f''\|_\infty \cdot \frac{1}{s_n^2}\sum_{i=1}^{n}\mathbb{E}\Big[X_i^2 \cdot \mathbf{1}_{|X_i|>\delta s_n}\Big]\,.$$

Le premier terme est ε fois une constante. Le second tend vers 0 par la condition de Lindeberg (Définition 3.1). Comme $\varepsilon > 0$ est arbitraire, on obtient :

$$\left|\mathbb{E}\left[f\left(\frac{S_n}{s_n}\right)\right] - \mathbb{E}[f(Y)]\right| \xrightarrow[n\to+\infty]{} 0$$

pour toute $f \in C_b^2(\mathbb{R})$. Par la Propriété 2.1, on conclut :

$$\frac{S_n}{s_n} \xrightarrow{\mathcal{L}} \mathcal{N}(0,1).$$

■

[LindebergRapport, Théorème 1.2, §1.2.2, p. 7–8]

Chapitre 4

Théorie générale des tests statistiques

4.1 Hypothèses nulle et alternative

Définition 4.1 (Test statistique)**.** Soit $(X_1, ..., X_n)$ un échantillon. On considère deux hypothèses mutuellement exclusives :

— l'**hypothèse nulle** H_0 : hypothèse que l'on cherche à mettre en défaut ;

— l'**hypothèse alternative** H_1 : hypothèse retenue si H_0 est rejetée.

Une **statistique de test** est une variable aléatoire $T_n = g(X_1, ..., X_n)$ dont la loi sous H_0 est connue ou peut être approchée. La **région de rejet** est un ensemble $R \subset \mathbb{R}$ tel que :

$$\text{si } T_n \in R, \text{ on rejette } H_0 \qquad ; \qquad \text{si } T_n \notin R, \text{ on ne rejette pas } H_0.$$

Définition 4.2 (Erreurs et niveau de signification)**.** On distingue deux types d'erreurs :

— **erreur de première espèce** : rejeter H_0 alors que H_0 est vraie ;

— **erreur de seconde espèce** : ne pas rejeter H_0 alors que H_1 est vraie.

Un test est de **niveau** $\alpha \in]0, 1[$ si :

$$P_{H_0}(T_n \in R) \leq \alpha.$$

Définition 4.3 (Niveau asymptotique)**.** Un test est de *niveau asymptotique* α si

$$\limsup_{n \to +\infty} \mathbb{P}_{H_0}(T_n \in R) \leq \alpha.$$

Définition 4.4 (p-valeur)**.** Pour une valeur observée t de T_n, la *p-valeur* est

$$p = \mathbb{P}_{H_0}(T_n \text{ aussi extrême ou davantage que } t).$$

On rejette H_0 si $p \leq \alpha$.

Chapitre 5

Approche exacte du test de Wilcoxon

Lemme 5.1 (Indépendance du signe et de la valeur absolue)**.** *Soit Z une variable aléatoire continue et symétrique autour de 0 de densité f_Z. Alors $\psi = \mathbf{1}_{Z>0}$ et $|Z|$ sont indépendants.*

Démonstration. Pour tout $t \geq 0$, on calcule :

$$P(|Z| \leq t) = P(-t \leq Z \leq t) = \int_{-t}^{t} f_Z(z)\,dz = 2\int_{0}^{t} f_Z(z)\,dz$$

car f_Z est paire. Par le Corollaire 1.1 (b), $P(\psi = 1) = \frac{1}{2}$. On a :

$$P(\psi = 1 \text{ et } |Z| \leq t) = P(0 < Z \leq t) = \int_{0}^{t} f_Z(z)\,dz$$

Donc :

$$P(\psi = 1) \cdot P(|Z| \leq t) = \frac{1}{2} \cdot 2\int_{0}^{t} f_Z(z)\,dz = \int_{0}^{t} f_Z(z)\,dz = P(\psi = 1 \text{ et } |Z| \leq t)$$

De même pour $\psi = 0$:

$$P(\psi = 0 \text{ et } |Z| \leq t) = P(-t \leq Z < 0) = \int_{-t}^{0} f_Z(z)\,dz = \int_{0}^{t} f_Z(z)\,dz$$

$$P(\psi = 0) \cdot P(|Z| \leq t) = \frac{1}{2} \cdot 2\int_{0}^{t} f_Z(z)\,dz = \int_{0}^{t} f_Z(z)\,dz = P(\psi = 0 \text{ et } |Z| \leq t)$$

Donc ψ et $|Z|$ sont indépendants. ■

Lemme 5.2. *Soient $Z_1, \ldots, Z_n$ mutuellement indépendantes, continues et symétriques autour de 0, de densités $f_{Z_1}, \ldots, f_{Z_n}$. On pose $\psi_i = \mathbf{1}_{Z_i>0}$. Alors :*

1. *chaque ψ_i suit une loi $\mathcal{B}(1/2)$;*
2. *les $\psi_1, \ldots, \psi_n$ sont mutuellement indépendants ;*

3. pour tout $(b_1, \ldots, b_n) \in \{0,1\}^n$ *:*

$$P(\psi_1 = b_1, \ldots, \psi_n = b_n \mid |Z_1|, \ldots, |Z_n|) = \left(\frac{1}{2}\right)^n$$

4. le vecteur $(\psi_1, \ldots, \psi_n)$ *est indépendant du vecteur des rangs* $(R_1, \ldots, R_n)$*.*

Démonstration. **(a)** Chaque Z_i est symétrique autour de 0, donc par le Corollaire 1.1 (b) :

$$P(\psi_i = 1) = P(Z_i > 0) = \frac{1}{2}$$

Et par le Corollaire 1.1 (a), $P(Z_i = 0) = 0$, donc $P(\psi_i = 0) = P(Z_i < 0) = \frac{1}{2}$. Donc $\psi_i \sim \mathcal{B}(1/2)$.

(b) Les Z_i sont mutuellement indépendantes. Or $\psi_i = \mathbf{1}_{Z_i>0}$ est une fonction mesurable de Z_i uniquement. Par le Lemme 6.1.6 de Bekka, les ψ_i sont mutuellement indépendants.

(c) Par le Lemme 5.1, pour chaque i, ψ_i et $|Z_i|$ sont indépendants. De plus les Z_i étant mutuellement indépendantes, conditionner par $(|Z_1|, \ldots, |Z_n|)$ ne change pas la loi des signes. Par (a) et (b) :

$$P(\psi_1 = b_1, \ldots, \psi_n = b_n \mid |Z_1|, \ldots, |Z_n|) = \prod_{i=1}^{n} P(\psi_i = b_i) = \left(\frac{1}{2}\right)^n$$

(d) Les rangs $(R_1, \ldots, R_n)$ sont une fonction déterministe de $(|Z_1|, \ldots, |Z_n|)$. Par le Lemme 6.1.6 de Bekka et le point (c), le vecteur des signes est indépendant du vecteur des rangs.

■

5.1 Le cas apparié (Signed Rank Test)

Hypothèse 5.1 (Cadre du test apparié)**.** On considère n paires d'observations (X_i, Y_i) pour $i = 1, ..., n$ et on pose

$$Z_i = Y_i - X_i, \quad i = 1, ..., n.$$

On suppose :

(i) $Z_1, ..., Z_n$ sont mutuellement indépendantes ;

(ii) soit $F_i(t) = \mathbb{P}\{Z_i \leq t\}$ pour $i = 1, ..., n$; F_i est continue et vérifie :

$$F_i(\theta + t) + F_i(\theta - t) = 1, \quad \forall t \in \mathbb{R},$$

où θ est la médiane commune, interprétée comme l'effet du traitement.

On souhaite tester

$$H_0 : \theta = 0 \quad \text{contre} \quad H_1 : \theta \neq 0.$$

Définition 5.1 (Indicateur de signe)**.** Pour chaque $i = 1, ..., n$, on pose

$$\psi_i = \mathbb{1}_{\{Z_i > 0\}}.$$

Le cas $Z_i = 0$ est de probabilité nulle sous l'Hypothèse 5.1 (ii).

Définition 5.2 (Rang)**.** Le *rang* R_i est la position de $|Z_i|$ dans la liste ordonnée $|Z_1| \leq ... \leq |Z_n|$.

Définition 5.3 (Statistique T^+)**.** La *statistique des rangs signés* de Wilcoxon est

$$T^+ = \sum_{i=1}^{n} R_i \cdot \psi_i.$$

Théorème 5.1 (distribution de T^+)**.** *Sous H_0 et l'Hypothèse 5.1 :*

1. *les $\psi_1, ..., \psi_n$ sont mutuellement indépendantes et $\psi_i \sim \mathcal{B}(1/2)$;*
2. *les (ψ_i) sont indépendants des (R_i) ;*

de sorte que la loi de T^+ sous H_0 ne dépend pas de la forme de la distribution des Z_i.

Démonstration. Étape 1 : Chaque $\psi_i \sim B(1/2)$ et les ψ_i sont mutuellement indépendants.

Sous H_0, chaque Z_i est symétrique autour de zéro, donc Z_i et $-Z_i$ ont la même distribution. Il vient :

$$\mathbb{P}(\psi_i = 1) = \mathbb{P}(Z_i > 0) = \mathbb{P}(-Z_i > 0) = \mathbb{P}(Z_i < 0) = \mathbb{P}(\psi_i = 0).$$

Ces deux probabilités étant égales et de somme 1, on conclut $\psi_i \sim B(1/2)$. L'indépendance mutuelle des ψ_i découle directement de l'indépendance des Z_i.

Étape 2 : Les (ψ_i) sont indépendants des (R_i).

On conditionne par $(|Z_1|, \ldots, |Z_n|) = (a_1, \ldots, a_n)$, qui déterminent entièrement les rangs. Pour tout $(b_1, \ldots, b_n) \in \{0, 1\}^n$, connaître $|Z_i| = a_i$ revient à savoir que $Z_i \in \{+a_i, -a_i\}$. Par symétrie ces deux cas sont équiprobables, et par indépendance des Z_i les choix de signe sont indépendants. On obtient :

$$\mathbb{P}(\psi_1 = b_1, \ldots, \psi_n = b_n \mid |Z_1| = a_1, \ldots, |Z_n| = a_n) = \left(\frac{1}{2}\right)^n.$$

Cette probabilité ne dépend pas de $(a_1, \ldots, a_n)$, donc pas des rangs. Les vecteurs (ψ_i) et (R_i) sont ainsi indépendants.

Étape 3 : La loi de T^+ ne dépend pas de F_i.

On construit des variables $V_1, \ldots, V_n$ indépendantes avec $\mathbb{P}(V_i = i) = \mathbb{P}(V_i = 0) = 1/2$. Par les étapes précédentes, $T^+ = \sum_{i=1}^n R_i \psi_i$ a la même loi que $\sum_{i=1}^n V_i$, qui ne dépend que de n et d'aucun paramètre de F_i.

■

5.2 Le cas non-apparié (Rank Sum Test)

Hypothèse 5.2. On a deux échantillons :

— $X_1, ..., X_m$ i.i.d. ;

— $Y_1, ..., Y_n$ i.i.d. ;

— $(X_i) \perp\!\!\!\perp (Y_j)$.

Définition 5.4. On range les $N = m + n$ observations de manière croissante. Puis on note S_j le rang de Y_j. On a alors la statistique de Wilcoxon (pour le cas non apparié)

$W = \sum_{j=1}^n S_j$

Théorème 5.2. *Sous H_0, toutes les $\binom{N}{n} = \binom{m+n}{n}$ façons de choisir n rangs parmi $\{1, ..., N\}$ pour le groupe Y sont équiprobables. La loi de W sous H_0 ne dépend donc pas de F.*

Démonstration. Sous H_0, $F = G$ et les $N = m + n$ observations $X_1, ..., X_m, Y_1, ..., Y_n$ sont i.i.d. de loi commune F continue. Comme F est continue, tous les $N!$ ordres sont équiprobables avec probabilité $1/N!$. Les $\binom{N}{n}$ façons de choisir les n positions occupées par les Y_j dans l'ordre global sont donc équiprobables, chacune avec probabilité $1/\binom{N}{n}$. La loi de W ne dépend que de ces $\binom{N}{n}$ configurations équiprobables et pas de F. ■

5.5 Implémentation algorithmique

5.5.1 Approche combinatoire exacte

Le calcul de la p-valeur exacte revient à dénombrer, sous H_0, les configurations équiprobables conduisant à une statistique au moins aussi extrême que la valeur observée.

Cas non-apparié.

— w_{obs} : valeur observée de W

— q : taille de chaque groupe

— $\binom{2q}{q}$: nombre de façons de choisir q rangs parmi $\{1, \ldots, 2q\}$ sous H_0

— $\sqcap_j^i$: nombre de façons d'écrire i comme somme de j entiers distincts

— $r = w_{\text{obs}} - \frac{q(q+1)}{2}$: rang réduit (Définition 5.5)

On range les $N = 2q$ observations par ordre croissant et on attribue les rangs 1 à $2q$. Sous H_0, les $\binom{2q}{q}$ façons de choisir q rangs pour le groupe Y sont équiprobables. On note w_{obs} la valeur observée de W et r le rang réduit associé.

$$\mathbb{P}(W \leq w_{\text{obs}}) = \frac{2\left(1 + \sum_{i=1}^{r}\sum_{j=1}^{q} \sqcap_j^i - \sum_{n=1}^{r-q}\left((r-q-n+1)\sqcap_{q-1}^{q-2+n}\right)\right)}{\binom{2q}{q}}$$

Définition 5.5 (Rang réduit)**.** On pose

$$r = W - W_{\min} = W - \frac{q(q+1)}{2}.$$

Ce changement de variable permet de renuméroter les totaux possibles en partant de 0, ce qui facilite le comptage par partitions d'entiers (Proposition 6.1).

Proposition 5.1 (Bijection de Wilcoxon)**.** *Le nombre de q-uplets $(a_1 < a_2 < \cdots < a_q)$ avec $a_i \in \{1, ..., 2q\}$ et $\sum a_i = T$ est égal au nombre de partitions ordinaires de $r = T - q(q+1)/2$ en au plus q parts, chacune $\leq q$.*

Démonstration. Soit $(a_1 < a_2 < \cdots < a_q)$ un tel q-uplet. On définit $b_i = a_i - i$ pour $i = 1, ..., q$. Comme $a_i \geq i$, on a $b_i \geq 0$. Comme $a_i \leq 2q$, on a $b_i = a_i - i \leq 2q - i$; on vérifie par un argument de monotonicité que $b_i \leq q$. La suite $(b_1, ..., b_q)$ est croissante au sens large car (a_i) est strictement croissante. La somme est

$$\sum_i b_i = \sum_i a_i - \sum_i i = T - \frac{q(q+1)}{2} = r.$$

L'application $\varphi : (a_1, ..., a_q) \mapsto (b_1, ..., b_q)$ est une bijection entre les q-uplets cherchés et les suites $(b_1 \leq \cdots \leq b_q)$ à valeurs dans $\{0, ..., q\}$ de somme r, qui correspondent aux partitions ordinaires de r en au plus q parts $\leq q$. ■

Exemple 5.1 (Cas apparié – effet d'un engrais)**.** On mesure la hauteur (en cm) de 5 plants de blé avant et après application d'un engrais. On teste $H_0 : \theta = 0$ contre $H_1 : \theta > 0$.

Étape 1 – Les données :

Plant i	Avant X_i	Après Y_i	$Z_i = Y_i - X_i$
1	12	15	$+3$
2	18	16	-2
3	10	17	$+7$
4	14	19	$+5$
5	16	15	-1

Étape 2 – Rangs :

Plant i	$\lvert Z_i \rvert$	Rang R_i	Signe
5	1	1	$-$
2	2	2	$-$
1	3	3	$+$
4	5	4	$+$
3	7	5	$+$

Étape 3 – Calcul de T^+ :

$$T^+ = 3 + 4 + 5 = 12, \quad T^- = 1 + 2 = 3.$$

Vérification : $T^+ + T^- = \frac{5\times 6}{2} = 15$. ✓

Étape 4 – Dénombrement : sous H_0, il y a $2^5 = 32$ configurations. Les configurations avec $T^- \leq 3$ sont :

T^-	Nombre de Configuration
0	aucun rang négatif
1	rang 1 négatif
2	rang 2 négatif
3	rang 3 négatif
3	rangs 1 et 2 négatifs

Soit 5 configurations au total.

Étape 5 – p-valeur et conclusion :

$$p = \frac{5}{32} \approx 0{,}156 > 0{,}05.$$

On ne rejette pas H_0 : on ne peut pas conclure à un effet significatif de l'engrais.

Exemple 5.2 (Cas non apparié – diamètre de troncs dans deux forêts)**.** On mesure le diamètre (en cm) de troncs d'arbres dans deux forêts distinctes. On teste $H_0 : F = G$

contre $H_1 : F \neq G$.

Groupe A (Forêt 1) : 10, 15, 22 cm ($m = 3$).

Groupe B (Forêt 2) : 13, 18 cm ($n = 2$).

Étape 1 – Fusion et classement des $N = 5$ observations :

Valeur	Rang	Groupe
10	1	A
13	2	B
15	3	A
18	4	B
22	5	A

Étape 2 – Calcul de W :

On somme les rangs du groupe B :

$$W = 2 + 4 = 6.$$

Étape 3 – Identification de r :

La somme minimale pour $n = 2$ rangs choisis parmi $\{1, \ldots, 5\}$ est $1 + 2 = 3$. On pose :

$$r = W - W_{\min} = 6 - 3 = 3.$$

Étape 4 – Dénombrement par la bijection de Wilcoxon :

Le nombre total de façons de choisir $n = 2$ rangs parmi $N = 5$ est $\binom{5}{2} = 10$.

Les configurations avec $W \leq 6$ sont :

Rangs de B	W
$\{1, 2\}$	3
$\{1, 3\}$	4
$\{1, 4\}$	5
$\{2, 3\}$	5
$\{1, 5\}$	6
$\{2, 4\}$	6

Soit 6 configurations avec $W \leq 6$.

Étape 5 – p-valeur et conclusion :

$$p = 2 \times \frac{6}{10} = \frac{12}{10}$$

On ajuste : pour un test bilatéral on prend le minimum entre $P(W \leq 6)$ et $P(W \geq 6)$. Ici $P(W \leq 6) = \frac{6}{10} = 0{,}6$, donc :

$$p = 2 \times \min\left(\frac{6}{10}, \frac{6}{10}\right) = 1{,}0 > 0{,}05.$$

On ne rejette pas H_0 : on ne peut pas conclure que les deux forêts ont des distributions différentes.

Cas apparié.

— t_{obs} : valeur observée de T^-, somme des rangs négatifs

— q : nombre de paires

— $\sqcap_n^i$: nombre de façons d'écrire i comme somme de n entiers distincts

On a $Z_i = Y_i - X_i$, chaque Z_i a un rang se trouvant entre 1 et q ainsi qu'un signe + ou −. Sous l'hypothèse H_0, les rangs ont autant de chance d'être négatifs que positifs, on a donc 2^q configurations possibles.

$$\mathbb{P}(T^- \leq t_{\text{obs}}) = \frac{2\left[1 + \sum_n \left(\sum_{i=n}^{t_{\text{obs}} - \binom{n}{2}} \sqcap_n^i\right)\right]}{2^q}$$

Exemple 5.3. (Pseudo-code Cas apparié)

1. Entrée : $(X_1, ..., X_n)$, $(Y_1, ..., Y_n)$, α
2. Pour $i = 1$ à n : calculer $Z_i = Y_i - X_i$
3. Supprimer les $Z_i = 0$, mettre à jour n
4. Trier $|Z_i|$ par ordre croissant, attribuer les rangs R_i
5. $T^+ = \sum_{Z_i > 0} R_i$
6. $T^- = \frac{n(n+1)}{2} - T^+$
7. $T = \min(T^+, T^-)$
8. Compter le nombre c de configurations avec somme $\leq T$ parmi 2^n
9. $p = \frac{2c}{2^n}$
10. Si $p \leq \alpha$: rejeter H_0, sinon ne pas rejeter H_0
11. Sortie : T^+, p, décision

Exemple 5.4. (Pseudo-code – Cas non apparié)

1. Entrée : $(X_1, ..., X_m)$, $(Y_1, ..., Y_n)$, α
2. Fusionner et trier les $N = m + n$ observations par ordre croissant
3. Attribuer les rangs $1, \ldots, N$ aux observations fusionnées
4. $W = \sum_{j=1}^{n} R_j$ où R_j est le rang de Y_j
5. Lister toutes les $\binom{N}{n}$ façons de choisir n rangs parmi $\{1, ..., N\}$
6. Pour chaque configuration, calculer la somme des rangs
7. Compter $c =$ nombre de configurations avec somme $\leq W$
8. $p = \frac{2 \cdot c}{\binom{N}{n}}$
9. Si $p \leq \alpha$: rejeter H_0, sinon ne pas rejeter H_0
10. Sortie : W, p, décision

Exemple 5.5. (Pseudo-code – Cas apparié asymptotique)

Pour $n > 25$ environ, le calcul exact est coûteux. On utilise l'approximation normale : sous H_0, $T^* \xrightarrow{L} \mathcal{N}(0, 1)$.

1. Entrée : $(X_1, ..., X_n)$, $(Y_1, ..., Y_n)$, α
2. Pour $i = 1$ à n : calculer $Z_i = Y_i - X_i$
3. Supprimer les $Z_i = 0$, mettre à jour n
4. Trier $|Z_i|$ par ordre croissant, attribuer les rangs R_i
5. $T^+ = \sum_{Z_i > 0} R_i$
6. $\mu = \frac{n(n+1)}{4}$
7. $\sigma = \sqrt{\frac{n(n+1)(2n+1)}{24}}$
8. $T^* = \frac{T^+ - \mu}{\sigma}$
9. $p = 2(1 - \Phi(|T^*|))$
10. Si $p \leq \alpha$: rejeter H_0, sinon ne pas rejeter H_0
11. Sortie : T^*, p, décision

Exemple 5.6. (Pseudo-code – Cas non apparié asymptotique)

Pour $m, n > 25$ environ, le calcul exact est coûteux. On utilise l'approximation normale : sous H_0, $W^* \xrightarrow{L} \mathcal{N}(0, 1)$.

1. Entrée : $(X_1, ..., X_m)$, $(Y_1, ..., Y_n)$, α
2. Fusionner et trier les $N = m + n$ observations par ordre croissant
3. Attribuer les rangs $1, \ldots, N$ aux observations fusionnées
4. $W = \sum_{j=1}^{n} R_j$ où R_j est le rang de Y_j
5. $\mu_W = \frac{n(N+1)}{2}$

6. $\sigma_W = \sqrt{\frac{mn(N+1)}{12}}$
7. $W^* = \frac{W - \mu_W}{\sigma_W}$
8. $p = 2(1 - \Phi(|W^*|))$
9. Si $p \leq \alpha$: rejeter H_0, sinon ne pas rejeter H_0
10. Sortie : W^*, p, décision

5.5.2 Approche asymptotique via Lindeberg

Pour $n > 25$ environ, le calcul exact est coûteux. On utilise l'approximation normale : sous H_0, $T^* \xrightarrow{\mathcal{L}} \mathcal{N}(0,1)$ (Théorème 6.3). La p-valeur est alors $2(1 - \Phi(|T^*|))$ où Φ est la fonction de répartition de $\mathcal{N}(0,1)$.

Chapitre 6

Approche asymptotique

6.1 Statistique sous H_0

Théorème 6.1. *Sous H_0 et l'Hypothèse 5.1,*

$$\mathbb{E}[T^+] = \frac{n(n+1)}{4} \quad et \quad \mathrm{Var}(T^+) = \frac{n(n+1)(2n+1)}{24}.$$

Démonstration. Sous H_0, les ψ_i sont i.i.d $\mathcal{B}(1/2)$ et indépendantes des rangs.

Par linéarité de l'espérance :

$$\mathbb{E}[T^+] = \sum_{i=1}^{n} R_i \cdot \mathbb{E}[\psi_i] = \frac{1}{2}\sum_{i=1}^{n} R_i = \frac{1}{2} \cdot \frac{n(n+1)}{2} = \frac{n(n+1)}{4}.$$

Les ψ_i étant indépendantes des rangs et entre elles :

$$\mathrm{Var}(T^+) = \sum_{i=1}^{n} R_i^2 \cdot \mathrm{Var}(\psi_i) = \frac{1}{4}\sum_{i=1}^{n} R_i^2 = \frac{1}{4} \cdot \frac{n(n+1)(2n+1)}{6} = \frac{n(n+1)(2n+1)}{24}.$$

■

Théorème 6.2. *Sous H_0 on a,*

$$\mathbb{E}[W] = \frac{n(m+n+1)}{2} \quad et \quad \mathrm{Var}(W) = \frac{mn(m+n+1)}{12}.$$

Démonstration. Sous H_0, les $N = m+n$ observations sont i.i.d. de loi commune F continue. On range toutes les observations par ordre croissant et on attribue les rangs $1, \ldots, N$. Les rangs $S_1, \ldots, S_n$ des $Y_1, \ldots, Y_n$ sont n valeurs distinctes tirées sans remise dans $\{1, \ldots, N\}$.

Calcul de $\mathbb{E}[W]$.

Par linéarité de l'espérance :

$$\mathbb{E}[W] = \sum_{j=1}^{n} \mathbb{E}[S_j].$$

Comme S_j est uniformément distribué sur $\{1, \ldots, N\}$:

$$\mathbb{E}[S_j] = \frac{1}{N} \sum_{k=1}^{N} k = \frac{1}{N} \cdot \frac{N(N+1)}{2} = \frac{N+1}{2}.$$

Donc :

$$\mathbb{E}[W] = \sum_{j=1}^{n} \frac{N+1}{2} = \frac{n(N+1)}{2} = \frac{n(m+n+1)}{2}.$$

Calcul de $\mathrm{Var}(W)$**.**

On utilise $\mathrm{Var}(W) = \mathbb{E}[W^2] - \mathbb{E}[W]^2$.

Étape 1 : développement de W^2**.**

$$W^2 = \left(\sum_{j=1}^{n} S_j \right)^2 = \sum_{j=1}^{n} S_j^2 + \sum_{j \neq k} S_j S_k.$$

En passant à l'espérance :

$$\mathbb{E}[W^2] = \sum_{j=1}^{n} \mathbb{E}[S_j^2] + \sum_{j \neq k} \mathbb{E}[S_j S_k].$$

Étape 2 : calcul de $\mathbb{E}[S_j^2]$**.**

S_j est uniforme sur $\{1, \ldots, N\}$ donc :

$$\mathbb{E}[S_j^2] = \frac{1}{N} \sum_{k=1}^{N} k^2 = \frac{1}{N} \cdot \frac{N(N+1)(2N+1)}{6} = \frac{(N+1)(2N+1)}{6}.$$

Étape 3 : calcul de $\mathbb{E}[S_j S_k]$ **pour** $j \neq k$**.**

Le couple (S_j, S_k) prend toutes les valeurs (a, b) avec $a \neq b$ de façon équiprobable parmi les $N(N-1)$ couples possibles, donc :

$$\mathbb{E}[S_j S_k] = \frac{1}{N(N-1)} \sum_{a \neq b} a \cdot b.$$

On utilise l'identité :

$$\sum_{a\neq b} a\cdot b = \left(\sum_{a=1}^{N} a\right)^2 - \sum_{a=1}^{N} a^2 = \frac{N^2(N+1)^2}{4} - \frac{N(N+1)(2N+1)}{6}.$$

On factorise par $N(N+1)$:

$$= N(N+1)\left[\frac{N(N+1)}{4} - \frac{2N+1}{6}\right] = N(N+1)\cdot\frac{3N(N+1)-2(2N+1)}{12}.$$

On développe le numérateur :

$$3N(N+1)-2(2N+1) = 3N^2+3N-4N-2 = 3N^2-N-2 = (3N+2)(N-1).$$

Donc :

$$\sum_{a\neq b} a\cdot b = \frac{N(N+1)(3N+2)(N-1)}{12}.$$

On obtient :

$$\mathbb{E}[S_jS_k] = \frac{N(N+1)(3N+2)(N-1)}{12\cdot N(N-1)} = \frac{(N+1)(3N+2)}{12}.$$

Étape 4 : assemblage.

Il y a n termes dans $\sum_j \mathbb{E}[S_j^2]$ et $n(n-1)$ termes dans $\sum_{j\neq k}\mathbb{E}[S_jS_k]$, donc :

$$\mathrm{Var}(W) = n\cdot\frac{(N+1)(2N+1)}{6} + n(n-1)\cdot\frac{(N+1)(3N+2)}{12} - \frac{n^2(N+1)^2}{4}.$$

On factorise par $n(N+1)$ puis on met sur 12 :

$$\mathrm{Var}(W) = \frac{n(N+1)}{12}\left[2(2N+1)+(n-1)(3N+2)-3n(N+1)\right].$$

On développe le crochet :

$$2(2N+1) = 4N+2, \quad (n-1)(3N+2) = 3nN+2n-3N-2, \quad 3n(N+1) = 3nN+3n.$$

En sommant :

$$4N+2+3nN+2n-3N-2-3nN-3n = N-n = m.$$

Donc :

$$\mathrm{Var}(W) = \frac{n(N+1)\cdot m}{12} = \frac{mn(m+n+1)}{12}.$$

■

6.2 Décomposition et vérification de la condition de Lindeberg

Proposition 6.1 (Décomposition de T^+)**.** *On pose*

$$V_j = j \cdot (\psi_j - 1/2), \quad j = 1, ..., n.$$

Alors :

(i) $T^+ - \mathbb{E}[T^+] = \sum_{j=1}^n V_j$ *;*

(ii) les V_j *vérifient l'Hypothèse 3.1 : indépendantes, centrées,* $\mathrm{Var}(V_j) = j^2/4$.

Démonstration. (i) On a

$$\sum_j V_j = \sum_j j(\psi_j - 1/2) = \sum_j j\psi_j - \frac{1}{2}\sum_j j = T^+ - \frac{n(n+1)}{4} = T^+ - \mathbb{E}[T^+].$$

(ii) $\mathbb{E}[V_j] = j(\mathbb{E}[\psi_j] - 1/2) = j(1/2 - 1/2) = 0$. Les V_j sont centrées. De plus, $\mathrm{Var}(V_j) = j^2 \cdot \mathrm{Var}(\psi_j) = j^2/4$. Les V_j sont indépendantes car les ψ_j le sont. ■

Lemme 6.1 (Condition de Lindeberg pour les V_j)**.** *La suite* $(V_j)_{1 \le j \le n}$ *vérifie la condition de Lindeberg.*

Démonstration. On calcule

$$s_n^2 = \sum_j \mathrm{Var}(V_j) = \frac{1}{4}\sum_j j^2 = \frac{n(n+1)(2n+1)}{24}.$$

Pour n grand, $s_n \sim n^{3/2}/\sqrt{12}$. Les V_j sont bornées : $|V_j| \le j/2 \le n/2$. On a

$$\frac{\max_{1 \le j \le n} |V_j|}{s_n} \le \frac{n/2}{\sqrt{n(n+1)(2n+1)/24}} \le \frac{n/2}{n^{3/2}/\sqrt{12}} = \frac{\sqrt{3}}{\sqrt{n}} \xrightarrow[n \to \infty]{} 0.$$

Pour n assez grand et pour tout $\delta > 0$ fixé, on a donc $|V_j| < \delta\, s_n$ pour tout $j \in \{1, ..., n\}$. Par conséquent, $\mathbb{1}_{\{|V_j| \ge \delta\, s_n\}} = 0$ pour tout j, et

$$\frac{1}{s_n^2}\sum_j \mathbb{E}\Big[V_j^2 \cdot \mathbb{1}_{\{|V_j| \ge \delta\, s_n\}}\Big] = 0.$$

La condition de Lindeberg est satisfaite. ■

6.3 Convergence en loi et niveau asymptotique

Théorème 6.3 (Convergence asymptotique de T^+)**.** *Sous H_0 et l'Hypothèse 5.1,*

$$T^* = \frac{T^+ - \mathbb{E}[T^+]}{\sqrt{Var[T^+]}} \xrightarrow{\mathcal{L}} \mathcal{N}(0,1).$$

Démonstration. On a : $T^+ - \mathbb{E}[T^+] = \sum_{i=1}^n R_i\psi_i - \frac{1}{2}\sum_{i=1}^n R_i = \sum_{i=1}^n R_i(\psi_i - \frac{1}{2})$

Les $R_i(\psi_i - 1/2)$ sont bornées car $|\psi_i - 1/2| \leq 1/2$ et $R_i \leq n$, donc : $|R_i(\psi_i - \frac{1}{2})| \leq \frac{n}{2}$

On a $s_n^2 = \mathrm{Var}(T^+) = \frac{n(n+1)(2n+1)}{24}$. On a donc : $\frac{\max_i |R_i(\psi_i - \frac{1}{2})|}{s_n} \leq \frac{n/2}{s_n} \sim \frac{\sqrt{3}}{\sqrt{n}} \to 0$

Donc pour n assez grand et tout $\delta > 0$, on a $|R_i(\psi_i - 1/2)| < \delta s_n$ pour tout i. On a donc : $\frac{1}{s_n^2}\sum_{i=1}^n \int_{|x|>\delta s_n} x^2 P_{X_i}(dx) = 0$

La condition de Lindeberg est satisfaite. On applique le théorème de Lindeberg et on obtient $T^* \xrightarrow{\mathcal{L}} \mathcal{N}(0,1)$. ■

Théorème 6.4 (Convergence asymptotique de W)**.** *Sous H_0, lorsque $m, n \to +\infty$,*

$$W^* = \frac{W - \mathbb{E}[W]}{\sqrt{\mathrm{Var}(W)}} \xrightarrow{\mathcal{L}} \mathcal{N}(0,1).$$

Démonstration. On part de la décomposition de $W - \mathbb{E}[W]$. Par linéarité on a :

$$W - \mathbb{E}[W] = \sum_{j=1}^n S_j - \frac{n(N+1)}{2} = \sum_{j=1}^n \left(S_j - \frac{N+1}{2}\right)$$

On pose $U_j = S_j - \frac{N+1}{2}$ pour $j = 1, \ldots, n$. Les U_j sont centrées par construction et indépendantes sous H_0. De plus elles sont bornées car $|U_j| \leq \frac{N-1}{2}$, donc :

$$\frac{\max_j |U_j|}{s_n} \leq \frac{(N-1)/2}{\sqrt{\mathrm{Var}(W)}} \to 0$$

lorsque $m, n \to +\infty$. Pour tout $\delta > 0$ fixé et m, n assez grands, on a $|U_j| < \delta s_n$ pour tout j, donc :

$$\frac{1}{s_n^2}\sum_{j=1}^n \mathbb{E}\Big[U_j^2 \cdot \mathbb{1}_{\{|U_j|>\delta s_n\}}\Big] = 0.$$

La condition de Lindeberg est satisfaite. On applique le théorème de Lindeberg (Théorème 3.1) et on obtient $W^* \xrightarrow{\mathcal{L}} \mathcal{N}(0,1)$. ■

Chapitre 7

Application sur données Réelles

7.1 Présentation des données

Les données sont des indicateurs de résultats des lycées en France, avec des indicateurs de valeur ajoutée des lycées (IVAL). Données disponibles sur data.gouv.fr.

Structure des données : Le fichier contient 32485 observations et 88 variables. Cela couvre les lycées généraux et technologiques. sur la période entre 2012 et 2025.

Définition 7.1. La valeur ajoutée d'un lycée est définie comme la différence entre le résultat observé et attendu.

Le résultat attendu est calculé par un modèle statistique prenant en compte les notes du brevet, les catégories socioprofessionnelles, le sexe, l'âge etc.

Pour cette analyse on conserve seulement 4 variables : VA réussite, VA mention, Secteur, Présents

En terme de temporalité, l'analyse s'effectue uniquement sur l'année 2025 pour les tests non appariés (permet de garantir qu'un lycée n'apporte qu'une seule fois sa contribution à l'échantillon).

Pour les tests appariés, on compare les périodes de 2015-2019 (période de la réforme Chatel) et 2022-2025(période de la réforme Blanquer). On supprime volontairement les années 2020 et 2021 en raison du caractère exceptionnel de ces années (années covid)

Variable	n	Médiane	Moyenne	Écart-type	Min	Max
VA réussite	2207	0.0	-0.21	2.66	-16	36
VA mention	2207	0.0	-0.22	6.59	-39	28
Effectif	2346	201.5	217.77	129.35	20	885

TABLE 7.1 – Statistiques descriptives des variables quantitatives (2025)

Secteur	Effectif	%
Public	1562	66.6
Privé sous contrat	784	33.4

TABLE 7.2 – Répartition des lycées par secteur (2025)

7.2 Statistiques descriptives

7.3 Justification du choix du test :

Remarque 7.1. Le test t de Student requiert comme hypothèse que les données suivent une loi normale.

Définition 7.2. (Test du χ^2 d'adéquation) Soit $x_1, \ldots, x_n$ un échantillon et P^0 une loi donnée. On note N_i l'effectif observé dans la classe O_i et $p_i^0 = P^0(O_i)$. On teste :

$$H_0 : P = P^0 \quad \text{contre} \quad H_1 : P \neq P^0$$

La statistique de test est :

$$T(X) = \sum_{i=1}^{k} \frac{(N_i - np_i^0)^2}{np_i^0}$$

Sous H_0, $T(X)$ suit asymptotiquement une loi $\chi^2(k-3)$, les deux degrés de liberté perdus correspondant à l'estimation de μ et σ^2 sur les données. On rejette H_0 au niveau α si $T(X) \geq \chi^2_{k-3,\,1-\alpha}$.

Dans notre cas on observe l'histogramme suivant : On remarque que nos données ne semblent pas suivre une loi normale. On va confirmer cette intuition grâce à un test du χ^2 d'adéquation.

(cf annexe) Après le test on obtient les résultats suivant :

Petits lycées : chi2 = 325.48, p-value = 0.0 Grands lycées : chi2 = 524.76, p-value = 0.0

On rejette donc l'hypothèse H_0 au risque $\alpha = 5\%$. La variable VA réussite ne suit donc pas une loi normale, que ce soit pour les petits lycées ou les grands. Cette hypothèse de normalité n'étant pas respectée le test t de Student n'est donc pas adapté.

Vérifions les autres hypothèses.

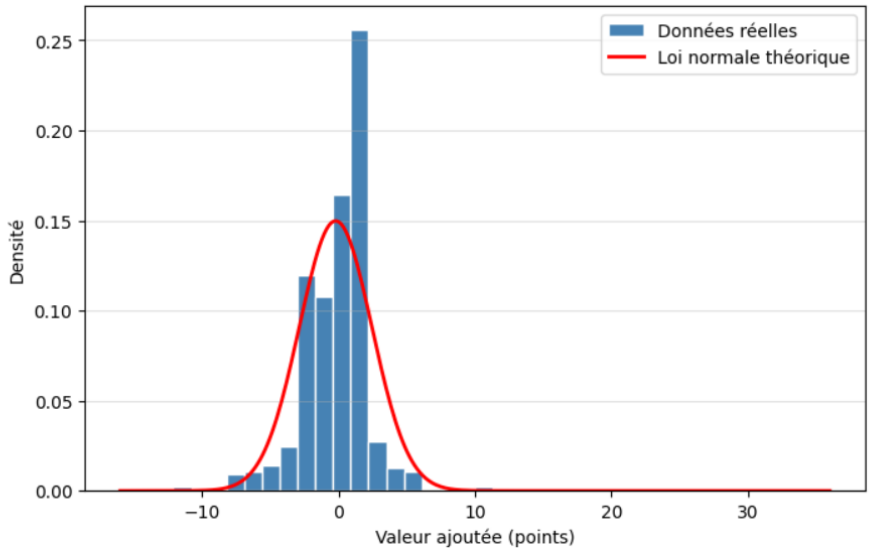


FIGURE 7.1 – VA réussite : données réelles vs loi normale théorique

La variable réussite est une variable continue (il s'agit évidemment de pourcentages).

Les deux échantillons sont indépendants ? Oui, ils le sont par construction : aucun lycée ne peut être présent dans les deux échantillons simultanément.

Enfin, la distribution est-elle identique dans les deux échantillons ? L'asymétrie des deux groupes est assez différente. On obtient une asymétrie de +1.396 pour les petits lycées et pour les grands lycées de -0.574.(cf cellule n°) les deux échantillons n'ont donc pas exactement la même distribution. Cela limitera la fiabilité du test. Cependant le nombre d'observations important permet de conserver de la robustesse.

7.4 Application du test

On souhaite déterminer si la taille d'un lycée influence sa valeur ajoutée au taux de réussite. Pour cela on fabrique deux échantillons petit et grand lycées.

On teste : $H_0 : F = G$ et $H_1 : F \neq G$ F et G représentent les distributions de VA des petits et grands lycées respectivement.

	Petits lycées	**Grands lycées**
m, n	1042	1165
Médiane VA réussite	+1	0
Moyenne VA réussite	+0,31	−0,68

TABLE 7.3 – Statistiques descriptives des deux groupes (2025)

Les résultats du test de Mann-Whitney (cas non apparié) sont représentés dans le tableau ci-dessus. On obtient $W = 766\,554$ et une $p_{\text{value}} = 0 < \alpha = 5\%$. On rejette alors H_0 avec

un risque de α. Il y a donc une différence significative entre les petits et grands lycées.

Conclusion : On observe que les petits lycées présentent une valeur ajoutée médiane supérieure à celle des grands lycées (+1 contre 0). Ce résultat est robuste quel que soit le seuil de séparation utilisé. Il suggère qu'au-delà d'un certain effectif, la taille d'un lycée est associée à une baisse de la valeur ajoutée. Cependant le test de Mann-Whitney ne permet pas de déterminer une taille optimale précise.

7.5 Analyse de la sensibilité

Pour être certain que le résultat du test ne dépend pas de la définition arbitraire de ce qu'est un grand lycée, on va réaliser le même test avec un seuil de séparation petit vs grand lycée différent.

On observe ces différents tests dans le tableau ci-dessous :

Percentile	n petits	n grands	Conclusion
30%	578	1629	Significatif
40%	814	1393	Significatif
50%	1042	1165	Significatif
60%	1276	931	Significatif
70%	1511	696	Significatif

TABLE 7.4 – Analyse de sensibilité — robustesse du résultat selon le seuil de séparation

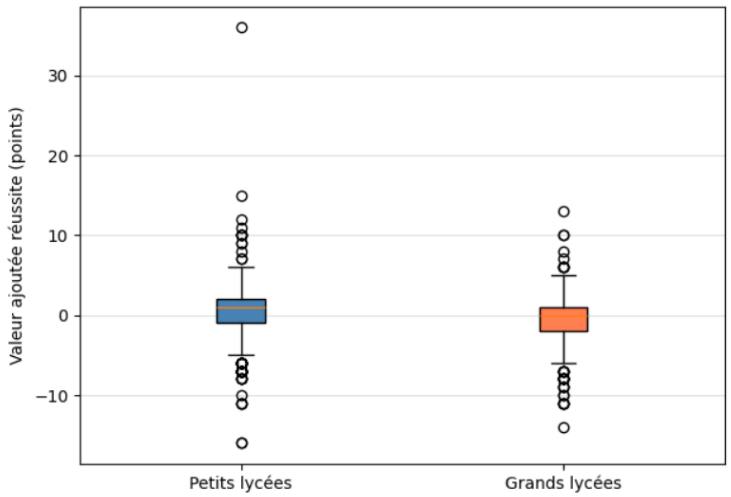


FIGURE 7.2 – VA réussite selon la taille du lycée (2025)

On observe que les petits lycées présentent une valeur ajoutée médiane supérieure à celle des grands lycées (+1 contre 0). Ce résultat est robuste quel que soit le seuil de séparation utilisé. Il suggère qu'au-delà d'un certain effectif, la taille d'un lycée est associée à une baisse de la valeur ajoutée. Cependant le test de Mann-Whitney ne permet pas de déterminer une taille optimale précise.

7.6 Application du test de Wilcoxon signé-rangé : la réforme Blanquer a-t-elle amélioré la valeur ajoutée ?

On cherche à déterminer si la réforme Blanquer a modifié la valeur ajoutée des lycées. Pour chaque lycée présent dans les deux périodes, on calcule sa VA moyenne sous Chatel (2015–2019) et sous Blanquer (2022–2025). On obtient $n = 2284$ lycées appariés.

On pose $Z_i = \text{VA}_{\text{Blanquer},i} - \text{VA}_{\text{Chatel},i}$ et on teste :

$$H_0 : \theta = 0 \quad \text{contre} \quad H_1 : \theta \neq 0$$

où θ désigne la médiane commune des différences.

Vérification des hypothèses

Les données sont naturellement appariées : chaque lycée est mesuré deux fois. La variable VA est continue. La symétrie des différences est vérifiée : skewness = 0,388 pour la VA réussite et −0,302 pour la VA mention, proches de zéro.

Résultats — VA réussite

On obtient $T^+ = 1\,252\,783$ et une p-value $= 6{,}12 \times 10^{-1}$. On ne rejette pas H_0 au seuil $\alpha = 5\%$.

La réforme Blanquer n'a pas modifié significativement la valeur ajoutée au taux de réussite. La médiane des différences est de −0,1 point, et 51,0% des lycées ont vu leur VA réussite se dégrader contre 47,6% qui se sont améliorés. Ces proportions quasi égales confirment l'absence d'effet.

Résultats — VA mention

On obtient $T^+ = 1\,187\,298$ et une p-value $= 1{,}15 \times 10^{-3}$. On rejette H_0 au seuil $\alpha = 5\%$.

La réforme a significativement dégradé la valeur ajoutée au taux de mention. La médiane des différences est de −0,33 point, et 52,1% des lycées ont vu leur VA mention se dégrader.

Analyse par secteur

La réforme est neutre pour le secteur public mais a significativement dégradé la VA mention du secteur privé (−1,58 point de médiane, 60,8% des lycées privés dégradés).

Secteur	n	Médiane diff	p-value	Conclusion
Public	1523	+0,33	$3{,}87 \times 10^{-1}$	Non significatif
Privé sous contrat	761	−1,58	$1{,}02 \times 10^{-9}$	Significatif

TABLE 7.5 – Impact de la réforme Blanquer sur la VA mention par secteur

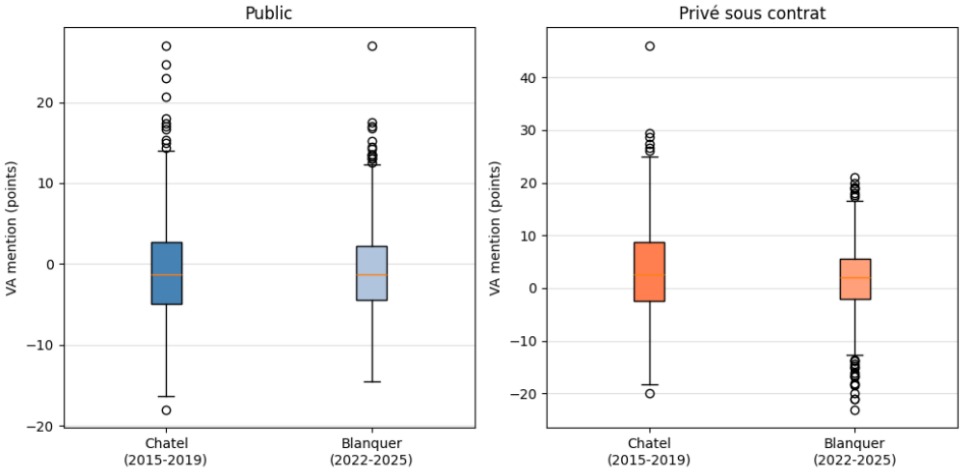


FIGURE 7.3 – VA mention avant et après la réforme Blanquer, par secteur

Conclusion

La réforme Blanquer n'a pas amélioré la réussite au bac. Elle a en revanche significativement dégradé les mentions, avec un impact asymétrique : le secteur public est resté stable tandis que le secteur privé a perdu en moyenne 1,58 point de VA mention.

7.7 Analyse de la puissance des tests

La puissance d'un test est la probabilité de rejeter H_0 quand H_1 est vraie. Ici on estime la puissance par bootstrap. Le concept est de tirer un sous-ensemble de données de taille n et d'appliquer le test. Puis on recommence pour un autre sous-ensemble de taille n, et ainsi de suite. On réalise cette étape un grand nombre de fois. La puissance est estimée comme la proportion de fois où H_0 est rejetée sur le nombre de tests réalisés. Il s'agit cependant d'une méthode d'estimation empirique.

Puissance Q1 : Mann-Whitney

Puissance Q2 : Wilcoxon signé — VA mention

La courbe bleue (Q1) atteint 80% de puissance dès $n = 80$ lycées par groupe, ce qui reflète un effet fort. La courbe orange (Q2) nécessite plus de 1500 paires pour atteindre 80%, ce qui reflète un effet plus faible. Sans données nationales, l'effet de la réforme sur les mentions serait indétectable.

n par groupe	Puissance
10	16,3%
20	30,3%
30	42,6%
50	64,7%
80	84,4%
100	90,7%
200	99,8%
1042	100,0%

TABLE 7.6 – Puissance du test de Mann-Whitney selon la taille des groupes

n paires	Puissance
20	6,0%
50	7,2%
100	10,3%
200	16,3%
500	32,5%
1000	58,6%
1500	75,2%
2270	89,3%

TABLE 7.7 – Puissance du Wilcoxon signé-rangé selon le nombre de paires

7.8 Limites et biais possibles :

Toute analyse statistique peut comporter des biais susceptibles d'influencer les résultats. Il est donc important de prendre connaissance de ces limites pour interpréter au mieux les résultats, leur fiabilité, et les conclusions que l'on peut en tirer. Une première limite concerne le test apparié. On n'a conservé que les lycées présents dans les deux périodes. Si deux lycées ont fusionné, la composition et le nombre d'élèves ont certainement changé de manière importante. De plus, si l'on considère que ce sont toujours les lycées les moins performants qui ferment, il est possible que l'effet de la réforme soit surestimé. Par ailleurs, les années Covid 2020 et 2021, même si elles ont été supprimées, ont tout de même pu avoir un impact sur les élèves, sur le suivi des connaissances et sur la complétion des programmes scolaires. Une deuxième limite porte sur les personnes présentes au lycée sur les années concernées. Ce ne sont pas les mêmes élèves, la même génération, la même culture, ni le même rapport au travail. On peut également ajouter l'arrivée et le développement des outils d'intelligence artificielle permettant l'aide aux devoirs. De nouveaux outils sont donc apparus, qui ont pu altérer le comportement de l'élève. Une autre limite vient directement du test. Le test de Wilcoxon permet de détecter s'il existe une différence significative, mais rien ne prouve que cette différence est causée par cette variable particulièrement — cela peut être dû aux nombreux facteurs évoqués précédemment, entre autres. De plus, des corrélations entre certains lycées peuvent être présentes, ces établissements partageant la

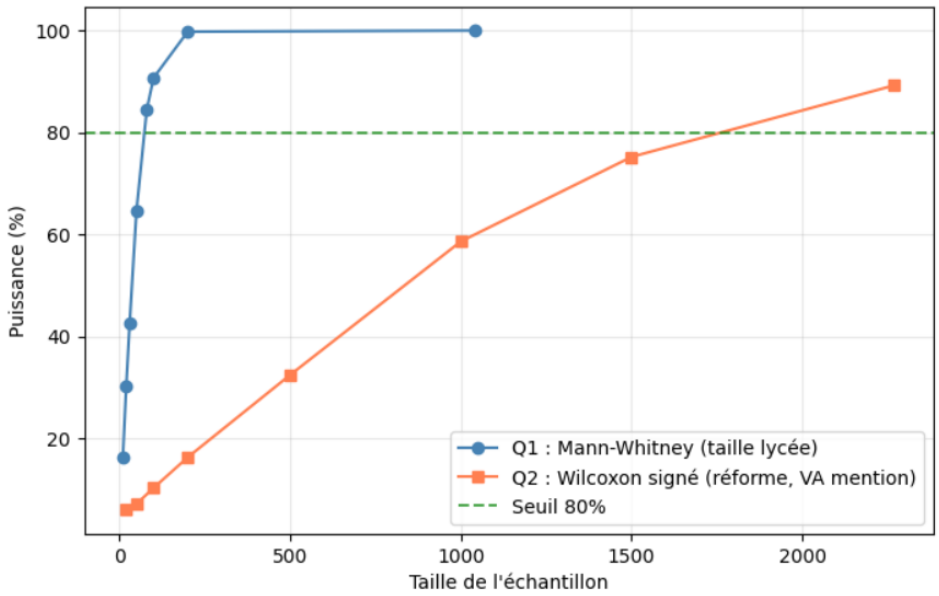


FIGURE 7.4 – Courbes de puissance des deux tests

même académie, la même politique éducative ou les mêmes ressources.

Il est cependant important de rappeler que cela n'invalide pas les résultats des tests, mais constitue une invitation à prendre en considération leur fiabilité ainsi que les possibles différences de résultats pouvant être dues à des variables ou phénomènes non pris en compte.

7.9 Conclusion

Ce mémoire avait pour objectif de présenter rigoureusement les tests non paramétriques de Wilcoxon et de justifier leur comportement asymptotique. On a établi que la statistique de test, sous H_0, ne dépend pas de la distribution des données — c'est la propriété fondamentale qui rend ces tests universellement applicables. On a ensuite montré, via le théorème central limite de Lindeberg, que cette statistique converge en loi vers une loi normale standard, ce qui permet d'utiliser l'approximation normale dès que l'échantillon est suffisamment grand. Ces outils ont été appliqués à des données réelles issues des indicateurs de valeur ajoutée des lycées français. Deux résultats se dégagent. D'une part, les petits lycées présentent une valeur ajoutée au taux de réussite significativement supérieure à celle des grands lycées, et ce résultat est robuste quel que soit le seuil de séparation retenu. D'autre part, la réforme Blanquer n'a pas modifié significativement le taux de réussite, mais a dégradé la valeur ajoutée au taux de mention — avec un impact asymétrique : le secteur public est resté stable tandis que le secteur privé a perdu en médiane 1,58 point de valeur ajoutée mention. L'analyse de puissance confirme que ces conclusions reposent sur des échantillons suffisamment grands pour détecter des effets de cette taille.

Ces résultats invitent à prolonger l'analyse. Le test de Mann-Whitney permet de détecter une différence significative entre petits et grands lycées, mais ne permet pas d'identifier une taille optimale précise. Des méthodes complémentaires — modèles de régression, analyses par seuils — permettraient d'aller plus loin dans cette direction. Plus généralement, ce mémoire illustre comment un outil statistique conçu en 1945 pour comparer des insecticides reste aujourd'hui un instrument rigoureux et accessible pour répondre à des questions de politique publique.

Annexe A

Code Python

A.1 Bibliothèques et chargement des données

```python
import matplotlib.pyplot as plt
import numpy as np
import pandas as pd
import seaborn as sns
from scipy import stats

sns.set(style="whitegrid")
np.random.seed(42)
```

```python
df = pd.read_csv("data/fr-en-indicateurs-de-resultat-des-lycees-gt_v2.csv", sep=";")
```

```python
df.info()
df.head()
```

```python
print(f"années disponibles : {df['Année'].unique()}\n")
print(f"secteurs : {df['Secteur'].unique()}")
```

```python
# on travaille sur l'année 2025 pour les tests non appariés
df_25 = df[df["Année"] == 2025]
print(f"{df_25.shape[0]} lycées en 2025")
missing = df_25.isna().sum().sort_values(ascending=False)
print(missing)
```

A.2 Statistiques descriptives (2025)

```
# on renomme les colonnes pour alléger l'écriture
reussite = "Valeur ajoutée du taux de réussite - Toutes séries"
mention  = "Valeur ajoutée du taux de mentions - Toutes séries"
effectif = "Présents - Toutes séries"

for nom, col in [("VA réussite", reussite), ("VA mention",
   mention), ("Effectif", effectif)]:
    v = df_25[col].dropna()
    print(nom, ": n =", len(v),
          " médiane =", round(v.median(), 2),
          " moyenne =", round(v.mean(), 2),
          " écart-type =", round(v.std(), 2),
          " min =", round(v.min(), 2),
          " max =", round(v.max(), 2))

n_pub  = len(df_25[df_25["Secteur"] == "public"])
n_priv = len(df_25[df_25["Secteur"] == "privé sous contrat"])
total  = n_pub + n_priv
print(f"public : {n_pub} ({round(n_pub / total * 100, 1)}%)")
print(f"privé  : {n_priv} ({round(n_priv / total * 100, 1)}%)")
print(f"total  : {total} lycées")
```

A.3 Justification du choix du test

```
va = df_25[reussite].dropna()

x = np.linspace(va.min(), va.max(), 300)
densite_normale = stats.norm.pdf(x, va.mean(), va.std())

plt.figure(figsize=(8, 5))
plt.hist(va, bins=40, density=True, label="données")
plt.plot(x, densite_normale, color="red", label="loi normale")
plt.xlabel("valeur ajoutée")
plt.ylabel("densité")
plt.title("Fig 1: Distribution de la valeur ajoutée du taux de
   réussite (2025)")
plt.legend()
plt.show()
```

```
mediane_eff = df_25[effectif].median()
```

```

petits = df_25[df_25[effectif] <= mediane_eff]
grands = df_25[df_25[effectif] >  mediane_eff]

va_petits = petits[reussite].dropna()
va_grands = grands[reussite].dropna()

print("médiane des effectifs :", mediane_eff)
print(f"nbr petits lycées = {len(va_petits)}")
print(f"nbr grands lycées = {len(va_grands)}")
print(f"total = {len(va_petits) + len(va_grands)}")
```

```
# on découpe en 8 classes équiprobables sous la normale estimée
for nom, groupe in [("petits lycées", va_petits), ("grands lycées", va_grands)]:
    mu = groupe.mean()
    sigma = groupe.std()

    bornes = [-np.inf]
    for i in range(1, 8):
        bornes.append(stats.norm.ppf(i / 8, mu, sigma))
    bornes.append(np.inf)

    effectifs_obs, _ = np.histogram(groupe, bins=bornes)
    effectif_theo = len(groupe) / 8
    stat = sum((o - effectif_theo) ** 2 / effectif_theo for o in effectifs_obs)

    # 5 ddl = 8 classes - 1 - 2 paramètres estimés (mu et sigma)
    p = 1 - stats.chi2.cdf(stat, 5)
    print(f"{nom}: chi2 = {round(stat, 2)}, p = {p:.2e}")
```

```
print(f"asymétrie petits lycées : {round(va_petits.skew(), 2)}")
print(f"asymétrie grands lycées : {round(va_grands.skew(), 2)}")
```

A.4 Question 1 : Mann-Whitney (Wilcoxon rang-somme)

```
W, p = stats.mannwhitneyu(va_petits, va_grands, alternative="two-sided")

print(f"petits lycées : médiane = {round(va_petits.median(), 2)}")
print(f"grands lycées : médiane = {round(va_grands.median(), 2)}")
print(f"W = {round(W)}, p = {round(p, 4)}")
if p < 0.05:
    print("différence significative")
else:
    print("différence non significative")

# ampleur et sens de la différence (Cliff's delta, entre -1 et 1)
cliff = 2 * W / (len(va_petits) * len(va_grands)) - 1
print(f"Cliff's delta = {round(cliff, 2)}")
```

```
boite = plt.boxplot([va_petits, va_grands], tick_labels=["petits lycées", "grands lycées"])
boite["boxes"][0].set(color="blue")
boite["boxes"][1].set(color="red")
plt.ylabel("valeur ajoutée réussite")
plt.title("Fig 2: VA réussite selon la taille du lycée")
plt.show()
```

```
# on vérifie que la conclusion ne dépend pas du seuil choisi
print("seuil   n petits   n grands   p-value   conclusion   Cliff's delta")
for pct in [30, 40, 50, 60, 70]:
    seuil = df_25[effectif].quantile(pct / 100)
    vp = df_25[df_25[effectif] <= seuil][reussite].dropna()
    vg = df_25[df_25[effectif] >  seuil][reussite].dropna()

    W, p = stats.mannwhitneyu(vp, vg, alternative="two-sided")
    cliff = 2 * W / (len(vp) * len(vg)) - 1

    if p < 0.05:
        conclusion = "significatif"
    else:
        conclusion = "non significatif"
```

```
    print(f"{pct}%       {len(vp)}       {len(vg)}       {round(p, 4)}    {conclusion}       {round(cliff, 2)}")
```

A.5 Question 2 : Wilcoxon signé-rangé

```
chatel   = df[df["Année"].isin([2015, 2016, 2017, 2018, 2019])]
blanquer = df[df["Année"].isin([2022, 2023, 2024, 2025])]

# VA moyenne de chaque lycée sur chaque période
moy_chatel = chatel.groupby("UAI").agg(
    reussite_c=(reussite, "mean"),
    mention_c =(mention,  "mean"),
    secteur   =("Secteur", "first"),
)
moy_blanquer = blanquer.groupby("UAI").agg(
    reussite_b=(reussite, "mean"),
    mention_b =(mention,  "mean"),
)

# on ne garde que les lycées présents sur les deux périodes
apparies = moy_chatel.join(moy_blanquer).dropna()
print(f"lycées appariés : {len(apparies)}")
```

```
diff_reussite = apparies["reussite_b"] - apparies["reussite_c"]
diff_mention  = apparies["mention_b"]  - apparies["mention_c"]

print(f"VA réussite : améliorés {len(diff_reussite[diff_reussite > 0])}, dégradés {len(diff_reussite[diff_reussite < 0])}")
print(f"VA mention  : améliorés {len(diff_mention[diff_mention > 0])}, dégradés {len(diff_mention[diff_mention < 0])}")

print(f"asymétrie diff réussite : {round(diff_reussite.skew(), 2)}")
print(f"asymétrie diff mention  : {round(diff_mention.skew(), 2)}")
```

```
# on enlève les différences nulles (ex aequo)
diff_r = diff_reussite[diff_reussite != 0]
T_r, p_r = stats.wilcoxon(diff_r, alternative="two-sided")

```

```
print(f"VA réussite : n = {len(diff_r)}")
print(f"médiane des différences = {round(diff_reussite.median(), 2)}")
print(f"T+ = {round(T_r)}, p = {round(p_r, 4)}")

if p_r < 0.05:
    print("différence significative")
else:
    print("différence non significative")
```

```
diff_m = diff_mention[diff_mention != 0]
T_m, p_m = stats.wilcoxon(diff_m, alternative="two-sided")

print(f"VA mention : n ={len(diff_m)}")
print(f"médiane des différences = {round(diff_mention.median(), 2)}")
print(f"T+ ={round(T_m)}, p ={round(p_m, 4)}")

if p_m < 0.05:
    print("différence significative")
else:
    print("différence non significative")
```

```
# r de rang, à partir de la loi de T+ sous H0
for nom, T, n in [("VA réussite", T_r, len(diff_r)), ("VA mention", T_m, len(diff_m))]:
    esperance = n * (n + 1) / 4
    ecart_type = np.sqrt(n * (n + 1) * (2 * n + 1) / 24)
    Z = abs(T - esperance) / ecart_type
    r = Z / np.sqrt(n)
    print(f"{nom}: Z = {round(Z, 2)}, r = {round(r, 3)}")
```

```
print("secteur   n           médiane diff       p-value   conclusion")
for nom, secteur in [("public", "public"), ("privé", "privé sous contrat")]:
    d = diff_mention[apparies["secteur"] == secteur]
    d_nz = d[d != 0]
    T, p = stats.wilcoxon(d_nz, alternative="two-sided")
    conclusion = "significatif" if p < 0.05 else "non significatif"
```

```
    print(f"{nom}:  n = {len(d)},    médiane = {round(d.median(), 2)},   p = {round(p, 4)},   {conclusion}")
```

```
fig, axes = plt.subplots(1, 2, figsize=(10, 5))

for ax, secteur, couleurs in [(axes[0], "public", ["blue", "darkblue"]), (axes[1], "privé sous contrat", ["red", "darkred"])]:
    bloc = apparies[apparies["secteur"] == secteur]
    boite = ax.boxplot([bloc["mention_c"], bloc["mention_b"]], tick_labels=["Chatel\n(2015-2019)", "Blanquer\n(2022-2025)"])
    boite["boxes"][0].set(color=couleurs[0])
    boite["boxes"][1].set(color=couleurs[1])
    ax.set_title(secteur)
    ax.set_ylabel("VA mention")

fig.suptitle("Fig 3: VA mention selon le secteur et la période")
plt.tight_layout()
plt.show()
```

A.6 Analyse de la puissance des tests

```
nbr_simulation = 5000

tailles = [10, 20, 30, 50, 80, 100, 200, len(va_petits)]
puissance_q1 = []

for n in tailles:
    cpt = 0
    for i in range(nbr_simulation):
        s1 = np.random.choice(va_petits.values, size=n, replace=True)
        s2 = np.random.choice(va_grands.values, size=n, replace=True)
        W, p = stats.mannwhitneyu(s1, s2, alternative="two-sided")
        if p < 0.05:
            cpt += 1
    puissance = round(cpt / nbr_simulation * 100, 1)
```

```
    puissance_q1.append(puissance)
    print(f"n = {n}, puissance = {puissance}%")
```

```
diff = diff_mention[diff_mention != 0].values
tailles_q2 = [20, 50, 100, 200, 500, 1000, 1500, len(diff)]
puissance_q2 = []

for n in tailles_q2:
    cpt = 0
    for i in range(nbr_simulation):
        echantillon = np.random.choice(diff, size=n, replace=
            True)
        T, p = stats.wilcoxon(echantillon)
        if p < 0.05:
            cpt += 1
    puissance = round(cpt / nbr_simulation * 100, 1)
    puissance_q2.append(puissance)
    print(f"n = {n}, puissance = {puissance}%")
```

```
plt.figure(figsize=(8, 5))
plt.plot(tailles, puissance_q1, "o-", label="Q1 Mann-Whitney")
plt.plot(tailles_q2, puissance_q2, "s-", label="Q2 Wilcoxon
    signé")
plt.axhline(y=80, color="green", linestyle="--", label="seuil
    80%")
plt.xlabel("taille de l'échantillon")
plt.ylabel("puissance (%)")
plt.title("Courbes de puissance des deux tests")
plt.legend()
plt.show()
```

Bibliographie

1. Wilcoxon, F. (1945). Individual comparisons by ranking methods. Biometrics Bulletin
2. Rapport sur le principe de Lindeberg. Document de cours.
3. Levrard, C. (2023) Notes de cours.
4. Bekka, B.(2022-2023). Probabilités. Université de Rennes
5. Wakaki, H. (2016). Basic Nonparametric Statistical Methods. Notes de cours, Université d'Hiroshima.
6. Lehmann, E.L. (1975).Nonparametrics : Statistical Methods Based on Ranks
7. Billingsley, P. (1995). Probability and Measure
8. Tao, T. (2010). 254A, Notes 2 : The central limit theorem.
9. Bibmath Formule de Taylor avec reste intégral.
10. Cadre, B. *Tests statistiques*. Notes de cours, ENS Rennes.